



深度学习

DEEP LEARNING-XIAOLIN HU

Part.03

回归与分类

● 大纲

- Logistic 回归
- Softmax 回归

● 回归和分类



给定数据点集合 $\mathbf{x}^{(n)} \in R^m$ 和相应的标签 $t^{(n)} \in \Omega$:

$\{(\mathbf{x}^{(1)}, t^{(1)}), (\mathbf{x}^{(2)}, t^{(2)}), \dots, (\mathbf{x}^{(N)}, t^{(N)})\}$, 对于一个新的数据点 $\mathbf{x}$, 预测它的标签

- 目标是找到一个映射

$$f: R^m \rightarrow \Omega$$

- 如果 Ω 是一个连续的集合, 称其为**回归(regression)**
- 如果 Ω 是一个离散的集合, 称其为**分类(classification)**






● 回顾: 多项式回归

- 考虑一个回归问题, 输入 x 和 输出 y 都是标量。寻找一个函数 $f: \mathbb{R} \rightarrow \mathbb{R}$ 来拟合数据
 - $f(x) = b + wx$
 - $f(x) = b + w_1x + w_2x^2$
 - $f(x) = b + \sum_{i=1}^9 w_ix^i$

MSE 训练:

$$\min_w \frac{1}{N} \sum_{n=1}^N \|f(x^{(n)}) - y^{(n)}\|_2^2$$



线性回归

- $f(\mathbf{x})$ 是线性的

$$f(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + b$$

偏置 (bias)

b 可以融入 θ 并且得到 $f(\mathbf{x}) = \theta^\top \mathbf{x}$

其中 $\mathbf{w} \in R^m, b \in R$.

- 设均方误差 (MSE) 为成本函数


$$E = \frac{1}{2N} \sum_{n=1}^N (f(\mathbf{x}^{(n)}) - t^{(n)})^2 = \frac{1}{2N} \sum_{n=1}^N (\mathbf{w}^\top \mathbf{x}^{(n)} + b - t^{(n)})^2$$

- 通过最小化成本函数来找到最优的 $\mathbf{w}^*$ 和 b^*


$$\left. \begin{aligned} \nabla_{\mathbf{w}} E &= \sum_{n=1}^N (\mathbf{w}^\top \mathbf{x}^{(n)} + b - t^{(n)}) \mathbf{x}^{(n)} = 0 \\ \nabla_b E &= \sum_{n=1}^N (\mathbf{w}^\top \mathbf{x}^{(n)} + b - t^{(n)}) = 0 \end{aligned} \right\} \mathbf{w}^*, b^*$$

● 线性回归

- 在特征空间，一个线性分类器对应一个超平面



线性可分




线性不可分

- 两种典型的线性分类器
 - 感知器
 - SVM

● 使用线性回归进行二分类


- 假定 $t \in \{0,1\}$ 。考虑一维特征的情况



- 回归
 - 预测连续的 $y = f(x)$
- 分类
 - 预测 $y = \begin{cases} 1, & \text{if } f(x) \geq 0.5 \\ 0, & \text{if } f(x) < 0.5 \end{cases}$

● 高维输入的情况


- 假定 $t \in \{0,1\}$ 。考虑 $\mathbf{x} \in R^m$ ，是否可以用线性回归进行分类？



- 回归
 - 预测连续的 $y = f(\mathbf{x})$
- 分类
 - 预测 $y = \begin{cases} 1, & \text{if } f(\mathbf{x}) \geq 0.5 \\ 0, & \text{if } f(\mathbf{x}) < 0.5 \end{cases}$


● 输入输出映射

使用线性函数 $f(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + b$ 将输入 $\mathbf{x} \in R^m$ 映射到一维的输出空间 $\{0,1\}$



● 使用非线性回归进行二分类

- $f(x)$ 可以是非线性函数，例如， **logistic sigmoid function**



- 回归
 - 预测连续的 $y = f(\mathbf{x})$
- 分类
 - 预测 $y = \begin{cases} 1, & \text{if } f(\mathbf{x}) \geq 0.5 \\ 0, & \text{if } f(\mathbf{x}) < 0.5 \end{cases}$

● 训练非线性回归模型

- $f(\mathbf{x})$ 是非线性的

$$f(\mathbf{x}) = h(\mathbf{w}^\top \mathbf{x} + b)$$

其中 $\mathbf{w} \in R^m, b \in R$.

- 设均方误差 (MSE) 为成本函数

$$E = \frac{1}{2N} \sum_{n=1}^N (f(\mathbf{x}^{(n)}) - t^{(n)})^2$$

- 通过最小化成本函数来找到最优的 $\mathbf{w}^*$ 和 b^*

$$\left. \begin{aligned} \nabla_{\mathbf{w}} E &= \sum_{n=1}^N (h(\mathbf{w}^\top \mathbf{x}^{(n)} + b) - t^{(n)}) \mathbf{x}^{(n)} = 0 \\ \nabla_b E &= \sum_{n=1}^N (h(\mathbf{w}^\top \mathbf{x}^{(n)} + b) - t^{(n)}) = 0 \end{aligned} \right\} \mathbf{w}^*, b^*$$

● 正态分布假设

- 假设标签服从均值为 $f(\mathbf{x}) = h(\mathbf{W}\mathbf{x} + \mathbf{b})$ 的正态分布:

$$p(t|\mathbf{x}) = \mathcal{N}(t; f(\mathbf{x})) \propto \exp\left(-\|t - f(\mathbf{x})\|_2^2\right)$$

(有时可能无法区分普通字体和斜体字体)

- 给定数据集 $\{(\mathbf{x}^{(1)}, t^{(1)}), \dots, (\mathbf{x}^{(N)}, t^{(N)})\}$ 。将 t 和 $\mathbf{x}$ 看作随机变量。条件数据似然函数为 (独立性假设)

$$P(t^{(1)}, \dots, t^{(N)} | \mathbf{X}) = \prod_{n=1}^N P(t^{(n)} | \mathbf{x}^{(n)})$$

- $\max \log P(t^{(1)}, \dots, t^{(N)} | \mathbf{X})$ 等同于

$$\min E = \frac{1}{2N} \sum_{n=1}^N \left\| f(\mathbf{x}^{(n)}) - t^{(n)} \right\|_2^2$$



● 二分类的伯努利分布假设

$$p(\mathbf{t}|\mathbf{x}) = \mathcal{N}(\mathbf{t}; f(\mathbf{x})) \propto \exp\left(-\|\mathbf{t} - f(\mathbf{x})\|_2^2\right)$$

- 对于回归问题(**t 是连续的**)，正态分布假设是自然的
- 对于分类问题(**t 是离散的**)，正态分布假设会很奇怪
- 对于分类问题的数据分布，有更合适的假设
— 伯努利分布

● Logistic 回归

- 对于二分类问题，一个0-1单元足以表示一个标签



- 尝试来学习条件概率 (已将 b 融入 θ)

$$P(t = 1|\mathbf{x}) = \frac{1}{1 + \exp(-\theta^\top \mathbf{x})} \triangleq h(\mathbf{x})$$


$$P(t = 0|\mathbf{x}) = 1 - P(t = 1|\mathbf{x}) = 1 - h(\mathbf{x})$$

其中 $\mathbf{x}$ 是输入， t 是标签

$P(t = 1|\mathbf{x})$ 是一个伯努利分布

● Logistic 回归

- 我们的目标是寻找一个 θ 值使得概率 $P(t = 1|\mathbf{x}) = h(\mathbf{x})$
 - 当 $\mathbf{x}$ 属于类别 1 时, 取很大的值
 - 当 $\mathbf{x}$ 属于类别 0 时, 取很小的值 (因此 $P(t = 0|\mathbf{x})$ 取很大的值)
- 我们实质上是在用另一个连续函数 h 来 “回归” 一个离散的函数 ($\mathbf{x} \rightarrow t$)



回归

预测 $y = h(\mathbf{x})$

分类

预测 $y = \begin{cases} 1, & \text{if } h(\mathbf{x}) \geq 0.5 \\ 0, & \text{if } h(\mathbf{x}) < 0.5 \end{cases}$

等同地

$y = \begin{cases} 1, & \text{if } \theta^T \mathbf{x} \geq 0 \\ 0, & \text{if } \theta^T \mathbf{x} < 0 \end{cases}$

● 最大化条件数据似然

- **回顾** 最大条件似然估计:
 - 1. 写出条件似然函数
 - 2. 取 $\log$ 并最大化
- 给定数据集 $\{(\mathbf{x}^{(1)}, t^{(1)}), \dots, (\mathbf{x}^{(N)}, t^{(N)})\}$ 其中 $t^{(n)} \in \{0, 1\}$
- 将 t 看作一个**伯努利**变量, 并且 $P(t = 1|\mathbf{x}) = h(\mathbf{x}; \boldsymbol{\theta})$ 。条件似然函数为

$$P(t^{(1)}, \dots, t^{(N)} | X; \boldsymbol{\theta}) = \prod_{n=1}^N h(\mathbf{x}^{(n)})^{t^{(n)}} (1 - h(\mathbf{x}^{(n)}))^{1-t^{(n)}}$$

- 最大化似然等同于最小化下式

$$\begin{aligned} E(\boldsymbol{\theta}) &= -\frac{1}{N} \ln P(t^{(1)}, \dots, t^{(N)}) \\ &= -\frac{1}{N} \sum_{n=1}^N \left(t^{(n)} \ln h(\mathbf{x}^{(n)}) + (1 - t^{(n)}) \ln(1 - h(\mathbf{x}^{(n)})) \right) \end{aligned}$$

● 交叉熵误差函数



- 对于带有二元标签的一组训练样本 $\{(\mathbf{x}^{(n)}, t^{(n)}) : n = 1, \dots, N\}$, 定义交叉熵误差 (*cross-entropy error*) 函数

$$E(\boldsymbol{\theta}) = -\frac{1}{N} \sum_{n=1}^N (t^{(n)} \ln(h(\mathbf{x}^{(n)})) + (1 - t^{(n)}) \ln(1 - h(\mathbf{x}^{(n)})))$$

$$E(\boldsymbol{\theta})^{(n)} = -t^{(n)} \ln(h(\mathbf{x}^{(n)})) - (1 - t^{(n)}) \ln(1 - h(\mathbf{x}^{(n)}))$$

➤ 如果 $t^{(n)} = 1$, 则
 $E(\boldsymbol{\theta})^{(n)} = -\ln(h)$

➤ 如果 $t^{(n)} = 0$, 则
 $E(\boldsymbol{\theta})^{(n)} = -\ln(1 - h)$



● 训练和测试

$$E(\boldsymbol{\theta}) = -\frac{1}{N} \sum_{n=1}^N \left(t^{(n)} \ln h(\mathbf{x}^{(n)}) + (1 - t^{(n)}) \ln(1 - h(\mathbf{x}^{(n)})) \right)$$

- 计算梯度(练习)

$$\nabla E(\boldsymbol{\theta}) = \frac{1}{N} \sum_n \mathbf{x}^{(n)} \left(h(\mathbf{x}^{(n)}) - t^{(n)} \right)$$

$$h(z) = \frac{1}{1 + \exp(-z)}$$
$$\frac{\partial h}{\partial z} = h(1 - h)$$

- 一些正则化项可以添加到成本函数中

$$J(\boldsymbol{\theta}) = E(\boldsymbol{\theta}) + \lambda ||\boldsymbol{\theta}||^2 / 2$$


- 训练: 学习 $\boldsymbol{\theta}$ 来最小化成本函数

$$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} - \alpha \nabla J(\boldsymbol{\theta})$$

其中 α 是学习率

- 测试: 对于新的输入 $\mathbf{x}$, 如果 $P(t = 1|\mathbf{x}) > P(t = 0|\mathbf{x})$ 则可以预测输入为类别 1, 否则就是类别 0

● 利用回归方法进行二分类


	线性回归	非线性回归
	$f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$	$f(\mathbf{x}) = g(\mathbf{w}^T \mathbf{x} + b)$ 其中 g 是非线性函数 1. 通常用MSE 损失函数 2. 如果 g 是 sigmoid 函数并且使用了 CSE 损失函数，那么就是 logistic 回归

● 大纲

- Logistic 回归
- Softmax 回归

● 向量的线性回归

- 如果 $t \in R^K$ 是一个连续向量，使用一个线性函数 $f_k(\mathbf{x})$ 来回归 t_k , $k = 1, \dots, K$:
 $f_k(\mathbf{x}) = \mathbf{w}_k^\top \mathbf{x} + b_k$, 其中 $\mathbf{w}_k \in R^m, b_k \in R$



● 向量的线性回归

- $f_k(\mathbf{x})$ 是线性的, $k = 1, \dots, K$: $f_k(\mathbf{x}) = \mathbf{w}_k^\top \mathbf{x} + b_k$, 其中 $\mathbf{w}_k \in R^m, b_k \in R$.
- 选择均方误差(MSE)作为损失函数

$$E = \frac{1}{2N} \sum_{n=1}^N \sum_{k=1}^K \left(f_k(\mathbf{x}^{(n)}) - t_k^{(n)} \right)^2$$

- 通过求解线性方程组找到最优的 $\mathbf{w}_k^*$ 和 b_k^*

$$\begin{aligned} \nabla_{\mathbf{w}_k} E &= \frac{1}{N} \sum_{n=1}^N \left(\mathbf{w}_k^\top \mathbf{x}^{(n)} + b_k - t_k^{(n)} \right) \mathbf{x}^{(n)} = 0 \\ \nabla_{b_k} E &= \frac{1}{N} \sum_{n=1}^N \left(\mathbf{w}_k^\top \mathbf{x}_k^{(n)} + b_k - t_k^{(n)} \right) = 0 \end{aligned} \quad \left. \vphantom{\begin{aligned} \nabla_{\mathbf{w}_k} E \\ \nabla_{b_k} E \end{aligned}} \right\} \mathbf{w}_k^*, b_k^*$$

● 向量的线性回归


- $f_k(\mathbf{x})$ 是非线性的, $k = 1, \dots, K$

$$f_k(\mathbf{x}) = h(\mathbf{w}_k^\top \mathbf{x} + b_k)$$

其中 $\mathbf{w}_k \in R^m, b_k \in R,$

$$h(z) = \frac{1}{1 + \exp(-z)}$$

或者其他函数



- 选择均方误差(MSE)作为损失函数

$$E = \frac{1}{2N} \sum_{n=1}^N \sum_{k=1}^K \left(f_k(\mathbf{x}^{(n)}) - t_k^{(n)} \right)^2$$

局部敏感度或局部梯度

- 设 $u_k = \mathbf{w}_k^\top \mathbf{x} + b_k$ 并且 $\delta_k = \frac{\partial E}{\partial u_k}$, 则 $\frac{\partial E}{\partial \mathbf{w}_k} = \delta_k \frac{\partial u_k}{\partial \mathbf{w}_k}$ 且 $\frac{\partial E}{\partial b_k} =$

$$\delta_k \frac{\partial u_k}{\partial b_k} = \delta_k$$

$$\delta_k = (f(u_k) - t_k) f'(u_k)$$

● 向量-矩阵形式

- 定义

$$\mathbf{W} = \begin{pmatrix} w_{11} & \cdots & w_{1m} \\ \vdots & \vdots & \vdots \\ w_{K1} & \cdots & w_{Km} \end{pmatrix} \quad \frac{\partial E}{\partial \mathbf{W}} = \begin{pmatrix} \partial E / \partial w_{11} & \cdots & \partial E / \partial w_{1m} \\ \vdots & \vdots & \vdots \\ \partial E / \partial w_{K1} & \cdots & \partial E / \partial w_{Km} \end{pmatrix}$$

m : 输入的数量; K : 输出的数量

- 输出: $\mathbf{f}(\mathbf{x}) = \mathbf{h}(\mathbf{W}\mathbf{x} + \mathbf{b})$, 其中 $\mathbf{f}, \mathbf{h}, \mathbf{b} \in R^K, \mathbf{x} \in R^m$

- 误差函数: $E = \frac{1}{2N} \sum_{n=1}^N \left\| \mathbf{f}(\mathbf{x}^{(n)}) - \mathbf{t}^{(n)} \right\|_2^2$

- 梯度

$$\nabla_{\mathbf{W}} E = \frac{1}{N} \sum_{n=1}^N \left(\mathbf{f}(\mathbf{x}^{(n)}) - \mathbf{t}^{(n)} \right) \odot \mathbf{f}'(\mathbf{x}^{(n)}) (\mathbf{x}^{(n)})^\top$$

$\in R^{K \times m}$

$$\nabla_{\mathbf{b}} E = \frac{1}{N} \sum_{n=1}^N \left(\mathbf{f}(\mathbf{x}^{(n)}) - \mathbf{t}^{(n)} \right) \odot \mathbf{f}'(\mathbf{x}^{(n)})$$

$\in R^K$

逐元素乘积

类别标签的表示

- 对于分类问题，给定 $\{(\mathbf{x}^{(1)}, t^{(1)}), \dots, (\mathbf{x}^{(N)}, t^{(N)})\}$ ，目标是找到从 $\mathbf{x}^{(n)}$ 到 $t^{(n)}$ 的映射

$$f: R^m \rightarrow \Omega$$

其中 Ω 是一个离散集合

- $t^{(n)}$ 可以是一个 (离散) 标量或向量

假设总共有5个类别

很少使用

标量表示

$$t^{(1)} = 1$$

$$t^{(3)} = 3$$

向量表示

$$\mathbf{t}^{(1)} = (1, 0, 0, 0, 0)^\top$$

$$\mathbf{t}^{(3)} = (0, 0, 1, 0, 0)^\top$$


经常使用

➤ 1-of-K 表示

➤ 性质: $t_k^{(n)} \in \{0, 1\}; \sum_k t_k^{(n)} = 1$

● 利用回归进行多标签分类

- 类别标签使用 1-of-K 表示方法，也可以使用线性回归进行分类



- 之前讨论的线性回归和非线性回归都可以使用

● 正态分布假设

- 假设标签服从均值为 $f(\mathbf{x}) = h(\mathbf{W}\mathbf{x} + \mathbf{b})$ 的正态分布:

$$p(\mathbf{t}|\mathbf{x}) = \mathcal{N}(\mathbf{t}; \mathbf{f}(\mathbf{x}), \mathbf{I}) \propto \exp\left(-\|\mathbf{t} - \mathbf{f}(\mathbf{x})\|_2^2\right)$$

(有时可能无法区分普通字体和斜体字体)

- 给定数据集 $\{(\mathbf{x}^{(1)}, t^{(1)}), \dots, (\mathbf{x}^{(N)}, t^{(N)})\}$ 。将 $\mathbf{t}$ 和 $\mathbf{x}$ 看作随机变量。条件数据似然函数为 (独立性假设)

$$P(t^{(1)}, \dots, t^{(N)} | \mathbf{X}) = \prod_{n=1}^N P(t^{(n)} | \mathbf{x}^{(n)})$$

- $\max \log P(t^{(1)}, \dots, t^{(N)} | \mathbf{X})$ 等同于

$$\min E = \frac{1}{2N} \sum_{n=1}^N \left\| f(\mathbf{x}^{(n)}) - t^{(n)} \right\|_2^2$$

● 分类的Multinoulli分布假设

$$p(\mathbf{t}|\mathbf{x}) = \mathcal{N}(\mathbf{t}; \mathbf{f}(\mathbf{x}), I) \propto \exp\left(-\|\mathbf{t} - \mathbf{f}(\mathbf{x})\|_2^2\right)$$

- 对于回归问题(**t 是连续的**)，正态分布假设是自然的
- 对于分类问题(**t 是离散的**)，正态分布假设会很奇怪
- 对于分类问题的数据分布，有更合适的假设
 - 对于 $K = 2$ 伯努利分布
 - 对于 $K > 2$ 范畴 Multinoulli/categorical 分布

● 回顾: 范畴 multinoulli/categorical 概率分布

- 一个离散随机变量 $\mathbf{t}$ 的概率分布, 变量 $\mathbf{t}$ 有 K 个不同的状态 K 是有限的

$$P(\mathbf{t} = k | \mathbf{p}) = p_k$$

其中 $\mathbf{p} \in [0,1]^K$ 并且 $\sum_{k=1}^K p_k = 1$

- 使用独热(one-hot)表示 $\mathbf{t} = (0, \dots, 1, \dots, 0)^\top$, 则

$$P(\mathbf{t}) = \prod_{k=1}^K P(\mathbf{t}_k = 1)^{t_k}$$

一个随机变量
0 或 1 的数值

数值: 1,2,3

$$P(\mathbf{t} = 1) = 0.2;$$

$$P(\mathbf{t} = 2) = 0.5;$$

$$P(\mathbf{t} = 3) = 0.3$$

One-hot: $(1,0,0)^\top, (0,1,0)^\top, (0,0,1)^\top$

$$P(\mathbf{t} = (1,0,0)^\top)$$

$$= P(\mathbf{t}_1 = 1)^1 P(\mathbf{t}_2 = 1)^0 P(\mathbf{t}_3 = 1)^0 = 0.2$$

相似地, $P(\mathbf{t} = (0,1,0)^\top) = 0.5;$


$$P(\mathbf{t} = (0,0,1)^\top) = 0.3$$

● 系统阐述

- 对于 K 分类问题($K > 2$), 尝试学习一个范畴 Multinoulli 分布 $P(\mathbf{t} = k|\mathbf{x})$ 其中 $k = 1, \dots, K$

- 使用独热(one-hot)表示 $\mathbf{t} = (0, \dots, 1, \dots, 0)^\top$, 则

$$P(\mathbf{t}|\mathbf{x}) = \prod_{k=1}^K P(\underbrace{\mathbf{t}_k}_{\text{一个随机变量}} = 1|\mathbf{x})^{\underbrace{t_k}_{\text{一个数值}}}$$



- 令 $P(\mathbf{t}_k = 1|\mathbf{x})$ 采取以下形式

$$P(\mathbf{t}_k = 1|\mathbf{x}) = \frac{\exp(\boldsymbol{\theta}^{(k)\top} \mathbf{x})}{\sum_{j=1}^K \exp(\boldsymbol{\theta}^{(j)\top} \mathbf{x})} \triangleq h_k(\mathbf{x})$$

明显地, $h_k(\mathbf{x}) \in (0,1)$ 并且 $\sum_{k=1}^K h_k(\mathbf{x}) = 1$

● 系统阐述

$$P(t_k = 1|\mathbf{x}) = \frac{\exp(\boldsymbol{\theta}^{(k)\top} \mathbf{x})}{\sum_{j=1}^K \exp(\boldsymbol{\theta}^{(j)\top} \mathbf{x})} \triangleq h_k(\mathbf{x})$$

- 给定一个测试输入 $\mathbf{x}$ ，对每一个 $k = 1, \dots, K$ 估计 $P(t_k = 1|\mathbf{x})$
- **目标:** 寻找一个 $\boldsymbol{\theta}$ 值使得概率 $P(t_k = 1|\mathbf{x})$
 - 当 $\mathbf{x}$ 属于第 k 个类时，取很大的值
 - 当 $\mathbf{x}$ 属于其他类时，取很小的值

其中 $\boldsymbol{\theta} = \begin{bmatrix} \boldsymbol{\theta}^{(1)} & \boldsymbol{\theta}^{(2)} & \dots & \boldsymbol{\theta}^{(K)} \end{bmatrix}^\top$.

- 由于 $h_k(\mathbf{x})$ 是一个 (连续的) 概率，我们需要将它转换为符合分类的离散值 **← 如何做到?**

● Softmax 函数

$$h_k(\mathbf{x}) = P(t_k = 1|\mathbf{x}) = \frac{\exp(\boldsymbol{\theta}^{(k)\top} \mathbf{x})}{\sum_{j=1}^K \exp(\boldsymbol{\theta}^{(j)\top} \mathbf{x})}$$

- 下列函数被称为 *softmax* 函数

$$\psi(z_i) = \frac{\exp(z_i)}{\sum_j \exp(z_j)} = \frac{\exp(z_i)}{\exp(z_i) + \sum_{j \neq i} \exp(z_j)} \in (0, 1)$$

- 如果 $z_i > z_j$ 对于所有的 $j \neq i$ 都成立
 - 则对于所有的 $j \neq i$, 有 $\psi(z_i) > \psi(z_j)$ 但其值小于1
- 如果 $z_i \gg z_j$ 对于所有的 $j \neq i$ 都成立
 - 则对于所有的 $j \neq i$, 有 $\psi(z_i) \rightarrow 1$, $\psi(z_j) \rightarrow 0$

● 最大条件似然

- 我们有

$$P(\mathbf{t}|\mathbf{p}) = \prod_{k=1}^K P(t_k = 1)^{t_k}$$

- 给定数据集 $\{(\mathbf{x}^{(1)}, \mathbf{t}^{(1)}), \dots, (\mathbf{x}^{(N)}, \mathbf{t}^{(N)})\}$ 。条件似然函数(独立性假设):

$$P(\mathbf{t}^{(1)}, \dots, \mathbf{t}^{(N)} | \mathbf{X}) = \prod_{n=1}^N \prod_{k=1}^K P(t_k^{(n)} = 1 | \mathbf{x}^{(n)})^{t_k^{(n)}}$$

- 最大化似然等同于最小化下式

$$E(\boldsymbol{\theta}) = -\frac{1}{N} \ln P(\mathbf{t}^{(1)}, \dots, \mathbf{t}^{(N)})$$

取 log 取负，然后最小化

$$= -\frac{1}{N} \sum_{n=1}^N \sum_{k=1}^K t_k^{(n)} \ln \frac{\exp(\boldsymbol{\theta}^{(k)\top} \mathbf{x}^{(n)})}{\sum_{j=1}^K \exp(\boldsymbol{\theta}^{(j)\top} \mathbf{x}^{(n)})}$$

● 交叉熵误差函数

$$E(\boldsymbol{\theta}) = -\frac{1}{N} \ln P(\boldsymbol{t}^{(1)}, \dots, \boldsymbol{t}^{(N)}) = -\frac{1}{N} \sum_{n=1}^N \sum_{k=1}^K t_k^{(n)} \ln \frac{\exp(\boldsymbol{\theta}^{(k)\top} \boldsymbol{x}^{(n)})}{\sum_{j=1}^K \exp(\boldsymbol{\theta}^{(j)\top} \boldsymbol{x}^{(n)})}$$

只有一个非零项!

● 交叉熵误差函数

$$\begin{aligned} E(\boldsymbol{\theta}) &= -\frac{1}{N} \ln P(\mathbf{t}^{(1)}, \dots, \mathbf{t}^{(N)}) = -\frac{1}{N} \sum_{n=1}^N \sum_{k=1}^K t_k^{(n)} \ln \frac{\exp(\boldsymbol{\theta}^{(k)\top} \mathbf{x}^{(n)})}{\sum_{j=1}^K \exp(\boldsymbol{\theta}^{(j)\top} \mathbf{x}^{(n)})} \\ &= -\frac{1}{N} \sum_{n=1}^N \ln P(t_k^{(n)} = 1 | \mathbf{x}^{(n)}) \end{aligned}$$

只有一个非零项!

- 这个函数被称为交叉熵误差(cross-entropy error)函数
- 为了求出它的梯度，首先将其分解为多个函数的复合

$$E(\boldsymbol{\theta}) = \frac{1}{N} \sum_{n=1}^N E^{(n)}(\boldsymbol{\theta}), \quad E^{(n)}(\boldsymbol{\theta}) = -\sum_{i=1}^K t_i^{(n)} \ln h_i^{(n)}$$

其中 $h_i^{(n)} = P(t_i^{(n)} = 1 | \mathbf{x}^{(n)}) = \frac{\exp(u_i^{(n)})}{\sum_{j=1}^K \exp(u_j^{(n)})}, \quad u_k^{(n)} = \boldsymbol{\theta}^{(k)\top} \mathbf{x}^{(n)}$

● 回顾: 两步求导

假设有:

- 独立的输入变量 $x_1, x_2, \dots, x_n$
- 相关的中间变量, $u_1, u_2, \dots, u_m$, 每一个中间变量都是 $x_1, x_2, \dots, x_n$ 的函数
- 相关的输出变量, $w_1, w_2, \dots, w_p$, 每一个输出变量都是 $u_1, u_2, \dots, u_m$ 的函数

对于任意的 $i \in \{1, 2, \dots, p\}$ 和 $j \in \{1, 2, \dots, n\}$ 可以推出

$$\frac{\partial w_i}{\partial x_j} = \sum_{k=1}^m \frac{\partial w_i}{\partial u_k} \frac{\partial u_k}{\partial x_j} \quad \text{对中间变量求和}$$

来自 wikipedia

本页中 x, w, u 表示一般的变量, 请勿与其他页上的符号混淆!

● 计算梯度

$$E(\boldsymbol{\theta}) = \frac{1}{N} \sum_{n=1}^N E^{(n)}(\boldsymbol{\theta}), \quad E^{(n)}(\boldsymbol{\theta}) = - \sum_{i=1}^K t_i^{(n)} \ln h_i^{(n)}$$

其中 $h_i^{(n)} = P(t_i^{(n)} = 1 | \mathbf{x}^{(n)}) = \frac{\exp(u_i^{(n)})}{\sum_{j=1}^K \exp(u_j^{(n)})}$, $u_k^{(n)} = \boldsymbol{\theta}^{(k)\top} \mathbf{x}^{(n)}$

$$\frac{\partial E^{(n)}}{\partial \boldsymbol{\theta}^{(k)}} = \frac{\partial E^{(n)}}{\partial u_k^{(n)}} \frac{\partial u_k^{(n)}}{\partial \boldsymbol{\theta}^{(k)}} = \sum_{i=1}^K \frac{\partial E^{(n)}}{\partial h_i^{(n)}} \frac{\partial h_i^{(n)}}{\partial u_k^{(n)}} \frac{\partial u_k^{(n)}}{\partial \boldsymbol{\theta}^{(k)}}$$

局部敏感度或局部
梯度

$$\frac{\partial E^{(n)}}{\partial h_i^{(n)}} = -t_i^{(n)} \frac{1}{h_i^{(n)}}$$

?

$$\frac{\partial u_k^{(n)}}{\partial \boldsymbol{\theta}^{(k)}} = \mathbf{x}^{(n)}$$

● 计算梯度

$$E(\boldsymbol{\theta}) = \frac{1}{N} \sum_{n=1}^N E^{(n)}(\boldsymbol{\theta}), \quad E^{(n)}(\boldsymbol{\theta}) = - \sum_{i=1}^K t_i^{(n)} \ln h_i^{(n)}$$

$$\text{其中 } h_i^{(n)} = P(t_i^{(n)} = 1 | \mathbf{x}^{(n)}) = \frac{\exp(u_i^{(n)})}{\sum_{j=1}^K \exp(u_j^{(n)})}, \quad u_k^{(n)} = \boldsymbol{\theta}^{(k)\top} \mathbf{x}^{(n)}$$

如果 $k \neq i$, u_k 仅出现在分母中

$$\frac{\partial h_i^{(n)}}{\partial u_k^{(n)}} =$$

if $k = i$, u_k 出现在分子和分母中

$$\frac{\partial h_i^{(n)}}{\partial u_k^{(n)}} =$$

● 计算梯度

$$E(\boldsymbol{\theta}) = \frac{1}{N} \sum_{n=1}^N E^{(n)}(\boldsymbol{\theta}), \quad E^{(n)}(\boldsymbol{\theta}) = - \sum_{i=1}^K t_i^{(n)} \ln h_i^{(n)}$$

$$\text{其中 } h_i^{(n)} = P(t_i^{(n)} = 1 | \mathbf{x}^{(n)}) = \frac{\exp(u_i^{(n)})}{\sum_{j=1}^K \exp(u_j^{(n)})}, \quad u_k^{(n)} = \boldsymbol{\theta}^{(k)\top} \mathbf{x}^{(n)}$$

如果 $k \neq i$, u_k 仅在分母中

$$\frac{\partial h_i^{(n)}}{\partial u_k^{(n)}} = - \frac{\exp(u_i^{(n)}) \exp(u_k^{(n)})}{\left(\sum_j \exp(u_j^{(n)}) \right)^2} = -h_k^{(n)} h_i^{(n)}$$

if $k = i$, u_k 同时在分子和分母中

$$\frac{\partial h_i^{(n)}}{\partial u_k^{(n)}} = \frac{\exp(u_k^{(n)})}{\sum_j \exp(u_j^{(n)})} - \frac{\left(\exp(u_k^{(n)}) \right)^2}{\left(\sum_j \exp(u_j^{(n)}) \right)^2} = h_k^{(n)} (1 - h_k^{(n)})$$

$$\text{因此 } \frac{\partial h_i^{(n)}}{\partial u_k^{(n)}} = h_i^{(n)} (\Delta_{i,k} - h_k^{(n)}) \quad \text{其中} \quad \Delta_{i,k} = \begin{cases} 1, & \text{if } i = k \\ 0, & \text{else.} \end{cases}$$

● 计算梯度

$$E(\boldsymbol{\theta}) = \frac{1}{N} \sum_{n=1}^N E^{(n)}(\boldsymbol{\theta}), \quad E^{(n)}(\boldsymbol{\theta}) = - \sum_{i=1}^K t_i^{(n)} \ln h_i^{(n)}$$

其中

$$h_i^{(n)} = P(t_i^{(n)} = 1 | \mathbf{x}^{(n)}) = \frac{\exp(u_i^{(n)})}{\sum_{j=1}^K \exp(u_j^{(n)}), \quad u_k^{(n)} = \boldsymbol{\theta}^{(k)\top} \mathbf{x}^{(n)}$$

$$\begin{aligned} \frac{\partial E^{(n)}}{\partial \boldsymbol{\theta}^{(k)}} &= \sum_{i=1}^K \frac{\partial E^{(n)}}{\partial h_i^{(n)}} \frac{\partial h_i^{(n)}}{\partial u_k^{(n)}} \frac{\partial u_k^{(n)}}{\partial \boldsymbol{\theta}^{(k)}} \\ &= \sum_{i=1}^K \left(-t_i^{(n)} \frac{1}{h_i^{(n)}} \right) \left(h_i^{(n)} (\Delta_{i,k} - h_k^{(n)}) \right) \left(\mathbf{x}^{(n)} \right) \\ &= - \left(\sum_{i=1}^K t_i^{(n)} \Delta_{i,k} - \sum_{i=1}^K t_i^{(n)} h_k^{(n)} \right) \mathbf{x}^{(n)} \\ &= - \left(t_k^{(n)} - h_k^{(n)} \right) \mathbf{x}^{(n)} \quad \underbrace{\hspace{1cm}}_{=1} \end{aligned}$$

● 计算梯度

$$E(\boldsymbol{\theta}) = \frac{1}{N} \sum_{n=1}^N E^{(n)}(\boldsymbol{\theta}), \quad E^{(n)}(\boldsymbol{\theta}) = - \sum_{i=1}^K t_i^{(n)} \ln h_i^{(n)}$$

$$\text{其中 } h_i^{(n)} = P(t_i^{(n)} = 1 | \mathbf{x}^{(n)}) = \frac{\exp(u_i^{(n)})}{\sum_{j=1}^K \exp(u_j^{(n)}), \quad u_k^{(n)} = \boldsymbol{\theta}^{(k)\top} \mathbf{x}^{(n)}$$

$$\frac{\partial E^{(n)}}{\partial \boldsymbol{\theta}^{(k)}} = \delta_k^{(n)} \mathbf{x}^{(n)}, \quad \text{其中 } \delta_k^{(n)} \triangleq \frac{\partial E^{(n)}}{\partial u_k^{(n)}} = - \left(t_k^{(n)} - h_k^{(n)} \right)$$

上式是局部敏感度或局部梯度.

对所有样本取平均

$$\begin{aligned} \frac{\partial E}{\partial \boldsymbol{\theta}^{(k)}} &= \frac{1}{N} \sum_{n=1}^N \frac{\partial E^{(n)}}{\partial \boldsymbol{\theta}^{(k)}} = - \frac{1}{N} \sum_{n=1}^N \left(t_k^{(n)} - h_k^{(n)} \right) \mathbf{x}^{(n)} \\ &= - \frac{1}{N} \sum_{n=1}^N \left(t_k^{(n)} - P(t_k^{(n)} = 1 | \mathbf{x}^{(n)}) \right) \mathbf{x}^{(n)} \end{aligned}$$

● 向量-矩阵形式

- 定义
$$\boldsymbol{\theta} = \begin{pmatrix} \theta_{11} & \cdots & \theta_{1m} \\ \vdots & \vdots & \vdots \\ \theta_{K1} & \cdots & \theta_{Km} \end{pmatrix} \quad \frac{\partial E}{\partial \boldsymbol{\theta}} = \begin{pmatrix} \partial E / \partial \theta_{11} & \cdots & \partial E / \partial \theta_{1m} \\ \vdots & \vdots & \vdots \\ \partial E / \partial \theta_{K1} & \cdots & \partial E / \partial \theta_{Km} \end{pmatrix}$$

m : 输入的数量; K : 输出的数量

- 输出: $\mathbf{f}(\mathbf{x})$ 是 softmax 函数, 其中 $\mathbf{f}, \mathbf{b} \in R^K, \mathbf{x} \in R^m$
- 交叉熵误差函数的梯度

$$\nabla_{\boldsymbol{\theta}} E = \begin{pmatrix} (\partial E / \partial \boldsymbol{\theta}^{(1)})^\top \\ \vdots \\ (\partial E / \partial \boldsymbol{\theta}^{(K)})^\top \end{pmatrix} = \frac{1}{N} \sum_{n=1}^N \left(\mathbf{f}(\mathbf{x}^{(n)}) - \mathbf{t}^{(n)} \right) \odot (\mathbf{x}^{(n)})^\top \quad \in R^{K \times m}$$

● 训练和测试

- 计算交叉熵误差函数的梯度

$$\nabla_{\boldsymbol{\theta}} E = \frac{1}{N} \sum_{n=1}^N \left(f(\mathbf{x}^{(n)}) - \mathbf{t}^{(n)} \right) \odot (\mathbf{x}^{(n)})^{\top}$$

- 与之前相同，一些正则化项可以加到成本函数中

$$J(\boldsymbol{\theta}) = E(\boldsymbol{\theta}) + \lambda \|\boldsymbol{\theta}\|^2 / 2$$


- 训练: 利用梯度 $\nabla J(\boldsymbol{\theta})$ 最小化成本函数

$$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} - \alpha \nabla J(\boldsymbol{\theta})$$

其中 α 是学习率

- 测试: 在 k 个类别中找出 $P(\mathbf{t}_k = 1 | \mathbf{x})$ 最大的类别，作为新输入 $\mathbf{x}$ 的预测标签

● 回顾: 随机梯度下降



- 在整个训练集中最小化成本函数的计算开销非常大
- 我们通常将训练集划分为较小的子集或 **minibatches** 然后在单个minibatches $(\mathbf{X}^{(i)}, \mathbf{y}^{(i)})$ 上优化成本函数，并取平均值

$$J(\theta) = \frac{1}{N'} \sum_{i=1}^{N'} L(\mathbf{X}^{(i)}, \mathbf{y}^{(i)}, \theta)$$
$$\mathbf{g} = \frac{1}{N'} \nabla_{\theta} \sum_{i=1}^{N'} L(\mathbf{X}^{(i)}, \mathbf{y}^{(i)}, \theta)$$
$$\theta = \theta - \eta \mathbf{g}$$

- 共 N' 个 minibatches
- minibatches 的大小可以取1到几百

● 引入偏置bias*

- 到目前为止，我们已经假设

$$h_k(\mathbf{x}) = P(t_k = 1|\mathbf{x}) = \frac{\exp(u_k^{(n)})}{\sum_{j=1}^K \exp(u_j^{(n)})} \quad u_k^{(n)} = \boldsymbol{\theta}^{(k)\top} \mathbf{x}^{(n)}$$

- 有时偏置项可以引入到 $u_k^{(n)}$ 中，参数成为 $\{\mathbf{W}, \mathbf{b}\}$

$$u_k^{(n)} = \mathbf{w}^{(k)\top} \mathbf{x}^{(n)} + b^{(k)}$$

- 很容易可以得到

$$\frac{\partial E}{\partial \mathbf{w}^{(k)}} = -\frac{1}{N} \sum_{n=1}^N \left(t_k^{(n)} - h_k(\mathbf{x}^{(n)}) \right) \mathbf{x}^{(n)}$$
$$\frac{\partial E}{\partial b^{(k)}} = -\frac{1}{N} \sum_{n=1}^N \left(t_k^{(n)} - h_k(\mathbf{x}^{(n)}) \right)$$

- 正则化通常只应用在 $\mathbf{W}$ 上

$$J(\mathbf{W}, \mathbf{b}) = E(\mathbf{W}, \mathbf{b}) + \lambda \|\mathbf{W}\|^2 / 2$$

● Softmax过度参数化*

- 有假设

$$h_k(\mathbf{x}) = P(t_k = 1|\mathbf{x}) = \frac{\exp(\boldsymbol{\theta}^{(k)\top} \mathbf{x})}{\sum_{j=1}^K \exp(\boldsymbol{\theta}^{(j)\top} \mathbf{x})} = \frac{\exp((\boldsymbol{\theta}^{(k)} - \boldsymbol{\phi})^\top \mathbf{x})}{\sum_{j=1}^K \exp((\boldsymbol{\theta}^{(j)} - \boldsymbol{\phi})^\top \mathbf{x})}$$

新的参数 $\hat{\boldsymbol{\theta}}^{(k)} \equiv \boldsymbol{\theta}^{(k)} - \boldsymbol{\phi}$ 会得到同样的预测结果

- 最小化交叉熵函数可以有无限多个解，因为

$$E(\boldsymbol{\theta}) = - \sum_{n=1}^N \sum_{k=1}^K t_k^{(n)} \ln \frac{\exp(\boldsymbol{\theta}^{(k)\top} \mathbf{x}^{(n)})}{\sum_{j=1}^K \exp(\boldsymbol{\theta}^{(j)\top} \mathbf{x}^{(n)})} = E(\boldsymbol{\theta} - \boldsymbol{\Phi})$$

其中 $\boldsymbol{\Phi} = (\boldsymbol{\phi}, \dots, \boldsymbol{\phi})$

● Softmax 回归和 logistic 回归的关系*

Softmax中令 $K = 2$

- 假设

$$h_1(\mathbf{x}) = P(t_1 = 1|\mathbf{x}) = \frac{\exp(\boldsymbol{\theta}^{(1)\top} \mathbf{x})}{\exp(\boldsymbol{\theta}^{(1)\top} \mathbf{x}) + \exp(\boldsymbol{\theta}^{(2)\top} \mathbf{x})} = \sigma(\boldsymbol{\theta}^{(1)} - \boldsymbol{\theta}^{(2)})$$

Sigmoid
函数

$$h_2(\mathbf{x}) = P(t_2 = 1|\mathbf{x}) = \frac{\exp(\boldsymbol{\theta}^{(2)\top} \mathbf{x})}{\exp(\boldsymbol{\theta}^{(1)\top} \mathbf{x}) + \exp(\boldsymbol{\theta}^{(2)\top} \mathbf{x})} = 1 - \sigma(\boldsymbol{\theta}^{(1)} - \boldsymbol{\theta}^{(2)})$$

如果定义一个新的变量 $\hat{\boldsymbol{\theta}} = \boldsymbol{\theta}^{(1)} - \boldsymbol{\theta}^{(2)}$ ，那么就和logistic 回归是相同的

- 每一个样本的误差函数



$$E^{(n)}(\boldsymbol{\theta}) = -t_1^{(n)} \ln h_1^{(n)} - t_2^{(n)} \ln h_2^{(n)} = -t_1^{(n)} \ln h_1^{(n)} - (1 - t_1^{(n)}) \ln(1 - h_1^{(n)})$$

与 logistic 回归相同

● 总结

- 非线性回归(线性回归视为特殊情况)
 - 输出: $\mathbf{f}(\mathbf{x}) = \mathbf{h}(\boldsymbol{\theta}^\top \mathbf{x})$, 其中 $\mathbf{h}$ 可以是任意函数
 - MSE 误差: $E = \frac{1}{N} \sum_{n=1}^N E^{(n)}, E^{(n)} = \frac{1}{2} \left\| \mathbf{h}(\mathbf{x}^{(n)}) - \mathbf{t}^{(n)} \right\|_2^2$
 - 梯度: $\nabla_{\boldsymbol{\theta}} E = \frac{1}{N} \sum_{n=1}^N \left(\mathbf{f}(\mathbf{x}^{(n)}) - \mathbf{t}^{(n)} \right) \odot \mathbf{f}'(\mathbf{x}^{(n)}) (\mathbf{x}^{(n)})^\top$
- Softmax 回归(logistic回归视为特殊情况)
 - 输出: $\mathbf{f}(\mathbf{x}) = \mathbf{h}(\boldsymbol{\theta} \mathbf{x})$, 其中 $\mathbf{h}$ 是 softmax 函数
 - 交叉熵误差: $E = \frac{1}{N} \sum_{n=1}^N E^{(n)}, E^{(n)} = -(\mathbf{t}^{(n)})^\top \ln \mathbf{h}^{(n)}$
 - 梯度: $\nabla_{\boldsymbol{\theta}} E = \frac{1}{N} \sum_{n=1}^N \left(\mathbf{f}(\mathbf{x}^{(n)}) - \mathbf{t}^{(n)} \right) (\mathbf{x}^{(n)})^\top$

● 回归方法进行分类

	线性回归	非线性回归
	$f(x) = \mathbf{w}^T \mathbf{x} + b$	$f(x) = g(\mathbf{w}^T \mathbf{x} + b)$ 其中 g 是非线性的 1. 通常用MSE损失函数 2. 如果 g 是 sigmoid 函数并且使用了 CSE 损失函数，那么就是 logistic 回归
	$f(x) = \mathbf{W}^T \mathbf{x} + b$	$f(x) = g(\mathbf{W}^T \mathbf{x} + b)$ 其中 g 是非线性的 1. 通常用MSE损失函数 2. 如果 g 是 softmax 函数并且使用了 CSE 损失函数，那么就是 softmax 回归

● 一般意义的“交叉熵”

- 对于两个分布 p 和 q 的交叉熵，在给定集合上有以下定义：

$$H(p, q) = E_p[-\log q] = H(p) + D_{\text{KL}}(p||q)$$


其中 $H(p)$ 是 p 的熵(entropy)， $D_{\text{KL}}(p||q)$ 是 q 与 p 的 Kullback-Leibler 散度

- 对于离散的 p 和 q

$$H(p, q) = - \sum_x p(x) \log q(x)$$

- 对于单标签分类， p 是一个独热(one-hot)向量 t

$$E^{(n)}(\theta) = - \sum_{i=1}^K t_i^{(n)} \ln h_i^{(n)}$$



● 总结

- Logistic 回归
 - Logistic sigmoid 函数
 - 交叉熵误差函数
- Softmax 回归
 - Softmax 函数
 - 交叉熵误差函数

对于分类问题，无论采用哪种损失函数，通常用1-of-K 的表示方式

